

零訓練開銷下以大型語言模型優化 IEEE 802.11b 競爭視窗： 記憶設計與多模型效能比較

Optimizing IEEE 802.11b Contention Window via Large Language Models with Zero Training Overhead: Experience Memory and Multi-Model Comparison

董惠筠 Hui-Yun Dong¹、黃冠勝 Guan-Sheng Huang²、洪晟峯 Cheng-Feng Hung³、
柯志亨 Chih-Heng Ke⁴、陳永昇 Yeong-Sheng Chen⁵

摘要 Abstract

無線區域網路中 IEEE 802.11b DCF 採固定二進位指數退避控制頻道存取，易導致在高節點密度時碰撞率上升並降低頻道使用效率，本研究提出基於大語言模型的 DCF 機制（LLM-Assisted DCF, LADCF），以不需額外訓練的大型語言模型（LLM），結合完整聊天歷史記憶，根據存取點蒐集的網路狀態動態調整競爭視窗（CW）。透過自建模擬器在 10 – 50 節點網路中，測試 Gemini-2.5-Flash、GPT-4o 與 Claude-3.5-Sonnet 三種 LLM 模型與傳統 DCF 的表現。研究顯示 LADCF 效能優於傳統 DCF 且記憶機制具備的上下文學習能力可有效提高網路效能。其中 Claude 在碰撞控制與穩定性表現最佳，Gemini 有最高峰值吞吐量，可作為 MAC 層動態參數控制的可行方案。

關鍵詞 Keywords：

IEEE 802.11b、大型語言模型、競爭視窗優化、上下文學習、智慧型代理人

¹ 國立金門大學資訊工程學系學生，donghuiyun446@gmail.com

² 國立金門大學資訊工程學系學生，sshain1220@gmail.com

³ 國立臺灣科技大學資工系博士，gyrgey18912@gmail.com

⁴ 國立金門大學資訊工程學系教授，smallko@gmail.com

⁵ 國立臺北教育大學資訊科學系教授，yschen@tea.ntue.edu.tw

壹、前言

無線區域網路（WLAN）中，IEEE 802.11b 標準所採用的分散式協調功能（Distributed Coordination Function, DCF）依賴二進位指數退避（Binary Exponential Backoff, BEB）演算法管理節點間的頻道競爭。BEB 採用固定策略調整競爭視窗（Contention Window, CW）：傳輸碰撞後倍增、成功後重設為 CW_{min}（最小競爭視窗），但這無法根據即時網路狀態動態調適，在高密度節點場景下易導致碰撞率顯著上升、頻道利用率大幅下降。深度強化學習（Deep Reinforcement Learning, DRL）雖已被應用於 CW 動態調整，但其訓練時間長、對環境變動敏感，且需大量互動樣本方能收斂，限制了實際部署的彈性。有鑑於此，大型語言模型（Large Language Model, LLM）所具備的預訓練與零樣本推理能力，提供了一種無需針對特定網路任務進行微調即可即時決策的新途徑。本研究旨在探討三項核心問題：一、配備聊天歷史記憶機制的 LLM 能否有效替代傳統 DCF 退避策略？二、Gemini-2.5-Flash、GPT-4o 與 Claude-3.5-Sonnet 三種主流 LLM 在不同節點密度下的效能差異為何？三、記憶機制的引入如何影響 LLM 的決策一致性與收斂行為？

現有研究已從多個方向嘗試改善 DCF 效能：自適應退避策略（如源於 MACAW 協定之 MILD，以及後續提出之 EIED 策略）試圖透過修改增加、減少倍率來提升公平性與吞吐量，然而這些方法仍僅依賴本地觀測資訊，無法精準掌握網路整體狀態，因此在節點數較多或負載變化劇烈時，其效能提升仍受限制。而 DRL 方法雖能動態調整 CW，但訓練成本高且難以遷移；近年 LLM 已被應用於功率控制、MAC 協定設計等無線網路任務，顯示其零樣本推理（Zero-shot Inference）的潛力。本研究旨在驗證，在無需針對任務特定額外訓練（Task-specific Training）的前提下，LLM 結合上下文學習（In-context Learning）與記憶機制於 CW 控制可行性，並分析不同模型間效能差異。

本研究提出 LADCF（LLM-Assisted DCF）架構，以存取點（AP）作為集中控制節點，週期性（每 3 秒）蒐集所有站台（STA）的即時吞吐量與碰撞率，並將其轉化為結構化提示（Structured Prompt）查詢遠端 LLM，由 LLM 推理產生的最佳 CW 值以 JSON 格式回傳後，AP 再將更新後的 CW 廣播至所有 STA。其核心之記憶機制採用 LangChain 的完整聊天歷史（RunnableWithMessageHistory）實作，保留歷次決策的吞吐量與碰撞率趨勢，使 LLM 能夠感知網路狀態的動態變化，並在每次決策時參考網路狀態的即時反饋數據、自身決策的歷史紀錄、趨勢提示，從而作出具備一致性與趨勢感知能力的調控判斷。

為驗證 LADCF 架構之效能，本研究以 Python 自行開發 IEEE 802.11b CSMA/CA 事件驅動模擬器，在 10 至 50 節點（以 10 為間距）的變動負載情境下，對 Gemini-2.5-Flash、GPT-4o、Claude-3.5-Sonnet 三種以 LLM 為核心之智慧型控制器與傳統 DCF 進行系統性比較。每種方法與節點數的組合獨立執行 90 秒模擬，每 3 秒為一個 LLM 決策週期，共產生 30 個決策點；隨機種子固定為 42（Random Seed），以確保各方法在完全相同的原始退避序列（Backoff Sequences）下進行公平對照。評估指標涵蓋碰撞率與總吞吐量，以及衡量決策一致性的吞吐量變異係數（CV）、CW 決策的時序與收斂行為。此外，本研究進一步透過消融實驗（Ablation Study）對比具備記憶機制與無記憶模式下之效能差異，以全面評估 LADCF 智慧代理人架構對網路效能之影響。

貳、文獻回顧

一、DCF 退避機制

IEEE 802.11 DCF 採用 CSMA/CA 機制，節點感測頻道閒置後等待 DIFS 時間，再隨機選取 $[0, CW]$ 範圍內的退避時槽，每過一個閒置時槽減一，歸零後才傳輸。碰撞發生後 BEB 演算法會將 CW 倍增直至 CW_{max} （本研究設為 1024），成功後重設為 CW_{min} （本研究設為 32）。然而，此固定策略在高密度節點場景下易導致碰撞頻繁、頻道利用率下降，促使後續研究提出多種自適應改良方案。Song 等人提出 EIED (Exponential Increase Exponential Decrease) 以及 Bharghavan 等人提出的 MILD (Multiplicative Increase Linear Decrease) 等策略試圖改善效能，但均因適應速度較慢，在網路負載動態變化時難以快速達到近似最佳的 CW 大小，因此整體效能提升仍有限 (Lin et al., 2023)。

二、強化學習於 MAC 層之優化

DQN 與 DDPG (Deep Deterministic Policy Gradients) 等深度強化學習方法已被應用於無線網路之 CW 動態優化。例如，Wydmanski 和 Szott (2021) 在 IEEE 802.11ax 網路環境下提出集中式 CW 優化框架 (CCOD)，顯示透過智慧型代理人 (Agent) 與模擬環境互動，能有效學習在不同網路條件下的調整策略。然而，DRL 在實際部署時面臨訓練收斂緩慢、高樣本需求及跨環境遷移困難等問題。本研究參照之基準研究 (Kumar et al., 2021) 已驗證 DQN 在 IEEE 802.11b 環境下的效能表現；有鑑於 DRL 的訓練成本限制，本研究將進一步探討具備零訓練開銷 (Zero Training Overhead) 特性之大型語言模型作為替代方案的可行性。

三、大型語言模型於無線網路之應用

大型語言模型已在多項無線網路任務中展現潛力。例如，WirelessLLM (Shao et al., 2024) 示範了利用提示工程執行功率分配任務之可行性；LLM4WM (Liu et al., 2025) 則透過全樣本與少樣本評估，驗證了 LLM 在多任務無線控制中的通用性。在 MAC 協定優化方面，LLM4MAC (Tan et al., 2025) 提出以 LLM 自動化設計 MAC 協定之架構；而 WirelessAgent (Tong et al., 2025) 則進一步整合了感知、記憶、規劃以及行動之代理人週期，展現了具備歷史感知能力的自主決策優勢。此外，Qiu 等人 (2024) 提出基於 LLM 之組合優化器，證明其在複雜網路規劃任務中的效能。上述研究共同支持本研究以 LLM 結合記憶機制優化 IEEE 802.11b CW 的技術方向。

參、研究方法

一、系統架構與流程

本研究所提出之 LADCF (LLM-Assisted DCF) 架構，旨在以存取點 (AP) 作為集中控制核心，並結合具備智慧代理人 (Intelligent Agent) 特質之大型語言模型，實現對 IEEE 802.11b 競爭視窗 (CW) 的智慧化調整。

(一) LLM 控制器內部架構

本研究將 LLM 控制器建構為一套遵循「感知 (Perception)、記憶 (Memory)、推理 (Reasoning)、行動 (Action)」之閉迴圈架構，其內部由四個功能層次串接構成，如圖 1 LLM 控制器內部模組架構圖所示。資料封裝模組負責將 AP 回報之節點數、吞吐量與碰撞率轉換為結構化 JSON 輸入，並套用統一的系統提示模板定義模型角色與退避邏輯。記憶管理模組為本架構之核心設計，透過 LangChain 的完整聊天歷史將當前輸入與歷次決策週期之歷史紀錄串接，使模型具跨週期的上下文感知與趨勢判斷能力。LLM 推理層透過 OpenRouter API 統一調用 Gemini-2.5-Flash、GPT-4o 與 Claude-3.5-Sonnet 三種模型實例，溫度係數設為 0 確保輸出確定性。輸出解析與校驗模組以正則表達式擷取 CW 數值，並確認其落於合法區間 [32, 1024]，若格式無效則自動回退至預設值 128。




圖 1 LLM 控制器內部模組架構圖

(二) 系統執行流程

系統整體執行流程如圖 2 系統運作流程圖所示。系統啟動時，AP 首先初始化統計數據並向 LLM 發出首次查詢以決定初始 CW 值。進入穩態後，系統依循週期性邏輯運作：AP 每 3 秒蒐集所有站台（STA）回報之即時吞吐量與碰撞率，連同當前節點數、上次決策之 CW 值，構成結構化提示查詢 LLM。LLM 透過 OpenRouter API 存取，並以 LangChain 之完整聊天歷史實作記憶機制，使模型得以觀察歷史趨勢而非僅依賴單次觀測進行決策。LLM 輸出之最佳 CW 值以 JSON 格式回傳；若輸出格式無效或數值超出合法區間 $[32, 1024]$ ，則自動回退至保守預設值 128。AP 取得有效 CW 值後廣播至所有 STA，各 STA 於當前決策週期內以該值作為固定 CW 進行退避。本研究利用 Python 事件驅動模擬器驗證上述架構，並透過統一參數設定模擬 AP 之廣播行為。




圖 2 系統運作流程圖

二、LLM 系統提示設計

所有 LLM 均採用相同的系統提示（System Prompt），明確定義模型角色與輸出規範。提示內容說明當前環境為 IEEE 802.11b 無線網路（傳輸速率 11 Mbps），要求模型扮演強化學習代理，根據當前網路指標（節點數、吞吐量與碰撞率）與歷史決策記錄（過去週期之 CW 值與其對應之效能反饋），決定最佳 CW 值（範圍限定為 32 至 1024 之整數），並強制以 JSON 格式回傳結果，此設計確保 LLM 輸出可機器解析，程式透過正則表達式提取 CW 值；若模型輸出格式無效，則預設回退至保守預設值 128，以維持網路運作。

肆、實驗成果與分析

一、環境與參數設定

本研究以 Python 實作 IEEE 802.11b CSMA/CA 離散事件模擬器，模擬參數如表 1 所示，根據 802.11b 標準定義之時間參數建構。為了確保實驗結果的可重複性與不同演算法間比較的公平性，本研究將隨機種子統一定義為 42，確保所有方法在相同節點數量下，在發送封包時的碰撞潛力與隨機挑戰是相同的，從而排除因隨機性造成的效能偶然偏差。

表 1 模擬環境參數設定

模擬參數	設定值
模擬標準	IEEE 802.11b (11 Mbps)
模擬時間	90 秒
決策視窗	3 秒 / 次
節點數量	10、20、30、40、50
封包大小	1,000 bytes
傳輸速率	11 Mbps
SIFS	10 μ s
DIFS	50 μ s
EIFS	= SIFS + DIFS + 192 + 112 μ s
時槽時間	20 μ s
DCF：CWmin / CWmax	32 / 1024
LLM 溫度	0（確定性輸出）
LLM 最大輸出 token	512
記憶機制	完整聊天歷史
隨機種子	42
LLM 服務供應商	OpenRouter API

二、實驗設計

本研究從五個面向對 DCF 與三種 LLM 進行系統性比較分析，如表 2 所示。每種（方法 × 節點數）組合獨立執行 90 秒模擬，每 3 秒為一個 LLM 決策週期，共產生 30 個決策點。標準 DCF 採用 IEEE 802.11b 規範之二進位指數退避演算法，CWmin 固定為 32，CWmax 固定為 1024，不引入任何學習或記憶機制，作為效能比較之基準線。Gemini-2.5-Flash、GPT-4o 與 Claude-3.5-Sonnet 三種 LLM 均搭配完整聊天歷史記憶機制，使模型於每次決策時可存取所有歷史吞吐量、碰撞率與 CW 調整紀錄。為驗證記憶機制之實際貢獻，同樣三種 LLM 另設無記憶版本，每次決策僅根據當前 3 秒決策週期內的網路狀態快照作出判斷，不保留任何歷史上下文，與有記憶版本形成對照。

表 2 五大分析面向與對應實驗條件彙整

分析面向	比較對象	節點情境	核心指標
整體碰撞率與吞吐量之比較	DCF 對比三種有記憶 LLM	10 - 50 節點	碰撞率（%）、總吞吐量（Mbps）
吞吐量穩定性分析	DCF 對比三種有記憶 LLM	10 - 50 節點	變異係數 CV
擁塞控制機制分析	三種有記憶 LLM	30 節點	CW 決策值時間序列
時序動態效能與收斂性分析	DCF 對比三種有記憶 LLM	30 節點	碰撞率與吞吐量時間序列、收斂速度
有無記憶機制對比分析	有記憶對比無記憶 LLM	10 - 50 節點	碰撞率（%）

三、整體碰撞率與吞吐量之比較

（一）關鍵效能指標之碰撞率的比較

從圖 3 可觀察到傳統 DCF 基準在所有測試情境下均呈現最高的碰撞率，且隨著節點數量的增加，碰撞率呈顯著的線性增長，從 10 個節點的 16.47% 攀升至 50 個節點的 33.40%。這明確指出傳統 DCF 在高密度環境下，由於其 BEB 機制缺乏對網路全局狀態的感知，導致頻繁的碰撞，嚴重限制了頻道利用率。而相較之下，具備記憶機制之各 LLM 控制器表現出顯著的改善。Claude-3.5-Sonnet 展現出最優異的碰撞率控制能力，其碰撞率始終維持在最低水平，於 50 個節點時僅為 5.02%。這表明其透過上下文學習與記憶機制，能有效預測網路競爭趨勢並將 CW 穩定在最優區間。Gemini-2.5-Flash 的表現亦相對穩定，在 50 個節點時碰撞率為 13.13%，顯示其記憶體機制在一定程度上緩解了碰撞問題。而 GPT-4o 的碰撞率則呈現先上升後下降的波動趨勢。

通過圖 3 可以發現由大語言模型主導的方法在特定密度下存在波動，最明顯的是 GPT-4o，它的碰撞率在 30 到 50 節點處呈現先上升後下降的波動趨勢，從 30 個節點的 13.06% 到在 40 個節點時達到 18.10% 的峰值，隨後在 50 個節點時回落至 12.15%。這種波動反映了記憶機制在特定網路密度下（如 40 節點）易陷入局部最優解陷阱（Local Optimum Trap）：當記憶內容引導 CW 調整至次優的穩定點後，模型傾向於維持現狀而減少了對全域解的探索空間，進而導致該密度下的效能瓶頸。




圖 3 各方法之碰撞率隨節點數變化之比較圖

(二) 關鍵效能指標之吞吐量的比較

從圖 4 可觀察到 DCF 的總吞吐量隨著節點數量的增加而持續下降，從 10 個節點的 4.96 Mbps 降至 50 個節點的 4.02 Mbps，這與其高碰撞率的結果相互印證，表明頻繁的碰撞直接導致了有效數據傳輸量的減少。相反地，具備記憶體機制的 LLM 系統普遍展現出更優異的吞吐量性能。Claude-3.5-Sonnet 在各類節點密度下均保持了較高的總吞吐量，且在節點數量增加時仍能維持在 5.0 Mbps 至 5.2 Mbps 之間，展現出卓越的數據傳輸效率。Gemini-2.5-Flash 的總吞吐量也相對穩定，維持在 4.8 Mbps 至 5.2 Mbps 的範圍內，證明其策邏輯能有效適應動態負載變化。GPT-4o 的總吞吐量則呈現波動，在 20 個節點時達到 5.00 Mbps，但在 40 個節點時略有下降，隨後在 50 個節點時回升至 4.83 Mbps。這呼應了它碰撞率的波動性，反映出該模型受到記憶機制影響，在特定場景下易陷入局部最優解，並因探索不足 (Insufficient Exploration) 而在次優穩定點產生決策震盪，未能始終鎖定全域最佳參數。




圖 4 各方法之總吞吐量隨節點數變化比較圖

四、吞吐量穩定性分析

本研究採用變異係數 (Coefficient of Variation, $CV = \text{標準差} / \text{平均值} \times 100\%$) 作為衡量指標，評估 90 秒模擬期間各方法在不同節點密度下的時序穩定性 (Time-series Stability)， CV 越低表示決策一致性越高。圖 5 呈現了各機制在不同節點數量下的吞吐量 CV 變化，並依據學術慣例將穩定性劃分為三個區域：穩定區域 ($CV < 10\%$)、中等穩定區域 ($10\% \leq CV \leq 25\%$) 和不穩定區域 ($CV > 25\%$)。

傳統 DCF 與 Claude-3.5-Sonnet 在所有測試節點數量下均表現出極高的吞吐量穩定性，其 CV 值始終保持在 1% 左右，遠低於 10% 的穩定閾值，屬於「穩定區域」。這表明儘管 DCF 的吞吐量絕對值較低，但其在運行過程中的波動性極小，行為具備高度可預測性。

Claude-3.5-Sonnet 則展現了高吞吐量與高穩定性兼具的卓越表現，其 CV 全程低於 2% (於 40 節點時達到最低值 0.53%)。這證實了該模型能精確鎖定網路最佳參數，避免了無意義的參數震盪，展現了極佳的決策收斂性。

Gemini-2.5-Flash 的穩定性則隨節點增加而呈現明顯的發散趨勢。在 10 個節點時， CV 為 3.17%，處於穩定區域；然而隨著節點增加，其 CV 逐漸攀升，至 50 個節點時達到 18.84%，進入中等穩定區域。這說明該模型在高負載環境下，其記憶機制在處理劇烈競爭時仍存在一定程度的決策不確定性。

GPT-4o 的穩定性表現呈現非單調 (Non-monotonic) 的複雜變化。在 10 個節點時，其 CV 高達 14.55% (中等穩定)；但在 20 個節點時， CV 顯著下降至 8.55%，進入穩定區域。然而，隨著密度的進一步增加，其 CV 再次上升，在 30 個節點時達到 13.67%，並在 40 和 50 個節點時均達到 18.81% 上下，持續處於中等穩定區域。此種「先降後升」的現象與前述之局部最優解陷阱相呼應：模型在 20 節點時達到了一個短暫的決策平衡點，但當環境複雜度進一步提升 (30 - 50 節點) 時，受限於探索能力不足，導致其決策在次優解附近產生持續性波動。




圖 5 各方法吞吐量變異係數 (CV) 隨節點數變化比較圖

五、競爭視窗控制機制分析

為了深入探討各 LLM 控制器在高負載環境下的內部決策邏輯，本研究進一步分析 30 節點場景下，各系統 CW 決策值隨時間之動態演進路徑，如圖 6 所示。CW 值的動態軌跡直接反映了智慧代理人對網路擁塞程度的即時感知能力。

Claude-3.5-Sonnet 展現了一種高度穩定且精確的 CW 控制策略。在初始階段，該模型能迅速感知擁塞並將 CW 調升至 640 以壓制碰撞，隨後精準地收斂於 512 附近（例如在 512 和 576 之間）。這種精準微調策略（Fine-tuning Control）表明，Claude-3.5-Sonnet 能夠精確地評估當前的網路擁塞程度，並將 CW 值維持在較優的平衡點，既能有效避免碰撞，又不會因過大的 CW 值而浪費網路資源。這也完美解釋了為何其在碰撞率、總吞吐量和吞吐量穩定性方面均表現出最佳的性能。

Gemini-2.5-Flash 對於 CW 值的調整展現出最為激進且快速的調整策略。在初始階段，其 CW 值從 32 迅速攀升至 1024，顯示其能快速感知到網路的高負載狀態並立即擴大 CW 以降低碰撞機率。然而，在達到最大 CW 值 (1024) 後，其策略轉為週期性的振盪，CW 值在 512 和 1024 之間頻繁切換。這種高頻振盪策略雖然能持續應對網路的動態變化，但也導致吞吐量穩定性的下降，這與圖 5 中其 CV 值隨節點數增加而顯著上升的觀測結果高度一致。

GPT-4o 則採取較為保守的階梯式（Staircase）增長策略。其 CW 值從 32 開始，經過數次平台期（例如在 128 和 256 處停留較長時間），最終在約 50 秒時達到並穩定在 1024。這種漸進式的調整方式給予系統更長的觀察和適應時間，避免了因過於激進的調整而導致的性能波動。這也解釋了為何其在 20 節點時的 CV 值會出現一個低谷（圖 5），因為系統在該負載下達到了短暫的穩定狀態。然而，這種策略也隱含了響應延遲（Response Latency）風險，使其在面對網路瞬時高壓時，吞吐量回升速度較為緩慢。




圖 6 在 30 節點場景下 CW 決策值之時間序列圖

六、時序動態效能與收斂性分析

根據系統設計，LLM 控制器在 $T = 0$ 時先根據初始節點數（無歷史觀測）進行首次決策，隨後每 3 秒更新一次參數，每次決策時可存取完整聊天歷史。為了更全面地評估各 LLM 機制在動態網路環境下的表現，本研究進一步分析了在 30 節點場景下，碰撞率與總吞吐量隨時間變化的關係，如圖 7 所示。這些時間序列數據揭示了各系統在面對持續負載時的收斂速度、穩定性以及自適應能力。

圖 7 中左圖為 30 節點下碰撞率隨時間變化關係圖。通過觀察可以發現 DCF 的碰撞率在整個 90 秒的觀察期間內始終維持在約 27% 至 29% 之高位，且波動相對較小。這表明傳統 DCF 機制在面對高負載時，碰撞問題持續存在，且缺乏有效的自適應調整能力來降低碰撞。相較之下，各 LLM 控制器均展現了優異的碰撞抑制能力。Gemini-2.5-Flash 在初始階段（約前 10 秒）表現出較高的碰撞率，但隨後迅速下降，並在約 15 秒後穩定在 5% 左右。這顯示其記憶體機制具有較快的收斂速度，能夠迅速適應網路變化並有效降低碰撞。GPT-4o 的碰撞率在初始階段（約前 10 秒）也較高，但隨後迅速下降，並在約 36 秒後穩定在 5% 左右。其收斂速度較 Gemini-2.5-Flash 緩慢，表明其記憶體機制響應網路擁塞的處理速度較慢。而 Claude-3.5-Sonnet 則展現了最為卓越的零樣本推理（Zero-shot Inference）能力，自模擬啟動初期即能精確判定最優視窗區間（碰撞率僅 6.26%），並於 6 秒後很好地維持在了低水平（碰撞率 5%），幾乎沒有波動。此即時收斂（Immediate Convergence）特性再次證明了其優化策略的精準性。

圖 7 中右圖為 30 節點下吞吐量隨時間變化關係圖。DCF 的吞吐量穩定在 4.3Mbps 左右，且波動較小。Gemini-2.5-Flash 與其碰撞率的快速下降相對應，吞吐量在初始階段較低（2.09 Mbps），但隨後迅速提升，並在約 9 秒後穩定在 4.7 Mbps 至 5.2 Mbps 之間，呈現出週期性的波動。這種波動與其 CW 決策的高頻振盪策略（圖 6）相符，表明其在追求高吞吐量的同時，犧牲了一定的穩定性。GPT-4o 的吞吐量在初始階段較低（約 2.09 Mbps），隨後迅速提升，並在 15 秒後穩定在 4.7 Mbps 至 5.2 Mbps 之間，同樣呈現出週期性的波動。Claude-3.5-Sonnet 的吞吐量與其極低的碰撞率相對應，在整個觀察期間內也始終維持在最高的水平（約 5.1 Mbps 至 5.2 Mbps），且全程波動極小。這表明其上下文感知能力不僅能抑制碰撞，更能維持極高的數據傳輸效率，達成了效能與穩定性的最佳平衡。




圖 7 在 30 節點場景下碰撞率（左）與吞吐量（右）隨時間變化關係圖

七、有無記憶機制對 LLM 控制器效能之對比分析

為驗證本研究所提之完整聊天歷史記憶機制在降低碰撞率、提升網路效能方面的作用，本研究進行了消融研究（Ablation Study）。讓三種 LLM 模型分別在有記憶和無記憶這兩種模式下進行對比測試，結果如圖 8 所示。無記憶模式下，LLM 每次決策僅根據當前決策週期（3 秒）的網路狀態快照，不參考過往的數據趨勢與決策歷史。

圖 8 對比了三種 LLM 在有記憶與無記憶模式下的碰撞率表現。可以發現研究的三種 LLM 控制器在啟用記憶體機制後，其碰撞率均顯著低於無記憶模式。隨著節點數量的增加，這種性能差距愈發明顯。在 50 節點的高負載場景下，Gemini-2.5-Flash、GPT-4o 與 Claude-3.5-Sonnet 在無記憶模式下的碰撞率分別高達 49.62%、37.74% 和 30.22%，而在有記憶模式下，其碰撞率則分別僅為 13.13%、12.15% 和 5.02%。

在無記憶模式下，實驗中所有模型的碰撞率均隨著節點數量的增加而惡化，這表明如果沒有記憶體機制來輔助決策，LLM 模型難以應對高密度網路中的資源競爭。相反，在有記憶模式下，各模型的碰撞率增長趨勢得到了有效抑制，甚至在某些情況下（如 GPT-4o 和 Claude-3.5 在 40 至 50 節點之間）出現了下降，顯示出記憶體機制在動態競爭視窗控制中的關鍵作用。




圖 8 有無記憶機制下各 LLM 碰撞率隨節點數之變化比較圖

伍、結論與建議

傳統 DCF 機制在高密度場景下因各節點僅依賴自身碰撞歷史獨立調整競爭視窗，缺乏全局感知能力，導致碰撞率隨節點數增加而顯著上升。本研究提出 LADCF 架構，以 AP 作為集中控制節點，透過 LLM 搭配完整聊天歷史記憶機制動態調整競爭視窗，並以 IEEE 802.11b CSMA/CA 模擬器在 10 至 50 節點場景下進行系統性驗證。實驗結果顯示，LADCF 在高密度場景（30–50 節點）之碰撞率較傳統 DCF 降低 20–28 個百分點，驗證了零訓練開銷下以 LLM 動態調整退避參數的技術可行性。三種模型中，Claude-3.5-Sonnet 在吞吐量穩定性、碰撞率控制及收斂速度三個維度表現最佳，是本

架構最適合的 LLM 選項；Gemini-2.5-Flash 峰值吞吐量突出但穩定性隨節點密度增加而下滑；GPT-4o 整體表現居中，在高密度場景下觀察到由記憶機制引發的局部最優陷阱現象，顯示現有記憶設計易使模型過早收斂於局部穩定點，存在探索與利用不平衡的問題。

針對上述研究限制，未來研究建議從三個方向延伸。第一，將 LADCF 框架擴展至 IEEE 802.11ax (Wi-Fi 6)，探索 OFDMA 多通道環境下 LLM 集中決策適應能力。第二，結合輕量化本地部署方案（如 Llama 3.2、Phi-4-mini）取代雲端 API，以降低每次決策之推理延遲，提升在實際 WLAN 場景中週期決策的可行性。第三，針對記憶機制導致的決策停滯（Decision Stagnation）或局部最優問題，未來可在提示詞中引入節點密度估算資訊並要求模型同時參考短期與長期歷史趨勢，或透過引入週期性的 CW 隨機擾動（Perturbation）機制，使系統有能跳出局部次優解，進一步提升決策品質。

參考文獻

- Bharghavan, V., Demers, A., Shenker, S., & Zhang, L. (1994). MACAW: A media access protocol for wireless LAN's. *Proceedings of the Conference on Communications Architectures, Protocols and Applications (SIGCOMM '94)*, 212-225.
- Kumar, A., Verma, G., Rao, C., Swami, A., & Segarra, S. (2021). Adaptive Contention Window Design Using Deep Q-Learning. *2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 4950-4954.
- Lin, C.-H., Cheng, M.-H., Hwang, W.-S., Shieh, C.-K., & Wei, Y.-H. (2023). A Rapidly Adaptive Collision Backoff Algorithm for Improving the Throughput in WLANs. *Electronics*, 12(15), Article 3324.
- Liu, X., Gao, S., Liu, B., Cheng, X., & Yang, L. (2025). LLM4WM: Adapting LLM for Wireless Multi-Tasking. *IEEE Transactions on Machine Learning in Communications and Networking*.
- Qiu, K., Bakirtzis, S., Wassell, I., Song, H., Zhang, J., & Wang, K. (2024). Large Language Model-Based Wireless Network Design. *IEEE Wireless Communications Letters*, 13(12), 3340-3344.
- Shao, J., Tong, J., Wu, Q., Guo, W., Li, Z., Lin, Z., & Zhang, J. (2024). WirelessLLM: Empowering Large Language Models Towards Wireless Intelligence. *Journal of Communications and Information Networks*, 9(2), 99-112.
- Song, N.-O., Kwak, B.-J., Song, J., & Miller, L. E. (2003). Enhancement of IEEE 802.11 distributed coordination function with exponential increase exponential decrease backoff algorithm. *IEEE Vehicular Technology Conference (VTC 2003-Spring)*, 4, 2775-2778.
- Tan, R., Li, R., & Zhao, Z. (2025). LLM4MAC: An LLM-Driven Reinforcement Learning Framework for MAC Protocol Emergence. In *Proceedings of the IEEE International Workshop on Signal Processing Advances in Wireless Communications (SPAWC 2025)*.
- Tong, J., Guo, W., Shao, J., Wu, Q., Li, Z., Lin, Z., & Zhang, J. (2025). WirelessAgent: Large Language Model Agents for Intelligent Wireless Networks. *arXiv preprint arXiv:2505.01074*.
- Wydmański, W., & Szott, S. (2021). Contention Window Optimization in IEEE 802.11ax Networks with Deep Reinforcement Learning. In *2021 IEEE Wireless Communications and Networking Conference (WCNC)* (pp. 1-6).